

**CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA DE MINAS GERAIS  
CAMPUS DIVINÓPOLIS**

**Pedro Henrique Rodrigues Pereira**

**OTIMIZAÇÃO DO PLANEJAMENTO DE MANUTENÇÕES PREVENTIVAS EM REDES  
DE TRANSMISSÃO DE ENERGIA ELÉTRICA: UMA ABORDAGEM HEURÍSTICA**

**Divinópolis**

**2025**

**PEDRO HENRIQUE RODRIGUES PEREIRA**

**OTIMIZAÇÃO DO PLANEJAMENTO DE MANUTENÇÕES PREVENTIVAS EM REDES  
DE TRANSMISSÃO DE ENERGIA ELÉTRICA: UMA ABORDAGEM HEURÍSTICA**

Trabalho de Conclusão de Curso  
apresentado no curso de Graduação em  
Engenharia de Computação do Centro  
Federal de Educação Tecnológica de Minas  
Gerais como requisito parcial para obtenção  
do título de Bacharel em Engenharia de  
Computação.

Orientador: Dr. André Luiz Maravilha Silva

**DIVINÓPOLIS**

**2025**

(Catalogação - Biblioteca Universitária – Campus Divinópolis – CEFET-MG)

P436o Pereira, Pedro Henrique Rodrigues.

Otimização do planejamento de manutenções preventivas em redes de transmissão de energia elétrica: uma abordagem heurística. / Pedro Henrique Rodrigues Pereira - Divinópolis, 2025.  
54 p. : il.

Orientador: Prof. Dr. André Luiz Maravilha Silva.

Trabalho de Conclusão de Curso (graduação) – Colegiado de Graduação em Engenharia de Computação do Centro Federal de Educação Tecnológica de Minas Gerais.

1. Otimização. 2. Manutenção Preventiva. 3. Energia Elétrica - Rede de Transmissão. 4. ROADEF/EURO Challenge 2020. 5. Programação Linear Inteira Mista. 6. Heurísticas. 7. Evolução Diferencial. I. Silva, André Luiz Maravilha. II. Centro Federal de Educação Tecnológica de Minas Gerais. III. Título.

CDU: 62:004(043)

Bibliotecária Responsável Maria Inês Passos Pereira Bueno CRB-6:2805

Dedico este trabalho aos meus pais,  
à minha namorada e aos amigos que  
me apoiaram ao longo de toda a  
graduação.

## **AGRADECIMENTOS**

Agradeço, em primeiro lugar, ao professor Dr. André Luiz Maravilha Silva por ter aceitado me orientar neste trabalho e por todo o apoio oferecido com paciência e dedicação. Sou grato por seus valiosos conselhos e ensinamentos.

Aos meus pais, Geraldo Magela Pereira e Gleicimar Aparecida Pereira, por terem me dado força e sustentabilidade para chegar a esse momento. Aproveito também a oportunidade para agradecer todo o suporte que me deram em casa e o amor dedicado, mesmo que a distância.

À minha namorada Camila Eduarda Andrade pelo apoio de sempre, palavras de conforto e companheirismo durante toda a jornada da graduação. Seu amor foi crucial para que eu chegasse até aqui.

Agradeço ao CEFET-MG Campus de Divinópolis e ao corpo de funcionários da casa, principalmente aos que me deram apoio e auxílio quando possível e sempre que necessário.

*“Eu gostaria que isso não tivesse acontecido em meu tempo”, disse Frodo. “Nem eu”, disse Gandalf, “e nem todos aqueles que vivem para ver tempos assim. Mas isso não cabe a eles decidir. **Tudo o que temos que decidir é o que fazer com o tempo que nos é dado.**”*

**J.R.R. Tolkien, A Sociedade do Anel**

## RESUMO

Este trabalho aborda a otimização do planejamento de manutenções preventivas em redes de transmissão de energia elétrica, utilizando como base o problema proposto no ROADEF/EURO Challenge 2020. A pesquisa se concentra na formulação de um modelo de Programação Linear Inteira Mista, do inglês *Mixed-Integer Linear Programming* (MILP) para minimizar os riscos associados às manutenções, considerando restrições de recursos e operacionais. Como estratégia de solução para o problema, este trabalho utiliza uma abordagem híbrida composta de duas etapas. Na primeira etapa, é desenvolvido uma relaxação combinatória da formulação apresentada, garantido uma solução para o problema que satisfaz as suas restrições, mas não garante a sua otimalidade. A etapa seguinte utiliza o Evolução Diferencial, do inglês *Differential Evolution* (DE) como estratégia de melhoria para refinar a solução obtida na primeira etapa. O desempenho da estratégia proposta é avaliada utilizando instâncias de teste fornecidas pela competição, e os resultados são comparados com os resultados da competição. As contribuições deste trabalho incluem o desenvolvimento de um modelo de otimização adaptado às necessidades da indústria de transmissão de energia elétrica e a implementação do DE para o problema de manutenção.

**Palavras-chave:** Otimização; Manutenção Preventiva; Redes de Transmissão de Energia Elétrica; ROADEF/EURO Challenge 2020; Programação Linear Inteira Mista; Heurísticas; Evolução Diferencial.

## ABSTRACT

This work addresses the optimization of preventive maintenance planning in power transmission networks, based on the problem proposed in the ROADEF/EURO Challenge 2020. The research focuses on formulating a *Mixed-Integer Linear Programming* (MILP) model to minimize the risks associated with maintenance activities, considering resource and operational constraints. As a solution strategy for the problem, this work employs a hybrid approach composed of two stages. In the first stage, a combinatorial relaxation of the presented formulation is developed, ensuring a solution that satisfies the problem's constraints but does not guarantee its optimality. The following stage utilizes *Differential Evolution* (DE) as an improvement strategy to refine the solution obtained in the first stage. The performance of the proposed strategy is evaluated using test instances provided by the competition, and the results are compared with those of the competition. The contributions of this work include the development of an optimization model adapted to the needs of the power transmission industry and the implementation of DE for the maintenance problem.

**Keywords:** Optimization; Preventive Maintenance; Power Transmission Networks; ROADEF/EURO Challenge 2020; Mixed-Integer Linear Programming; Heuristics; Differential Evolution.



## LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo de uma solução factível . . . . .	13
Figura 2 – Fluxograma da estratégia híbrida Gurobi/DE . . . . .	25
Figura 3 – Cruzamento Exponencial . . . . .	27
Figura 4 – Resultados do Gurobi/DE para instância A em 15 minutos . . . . .	32
Figura 5 – Resultados do Gurobi/DE para instância B em 15 minutos . . . . .	33
Figura 6 – Resultados do Gurobi/DE para instância C em 15 minutos . . . . .	33

## LISTA DE TABELAS

Tabela 1 – Características das instâncias propostas para competição ROADEF/EURO Challenge 2020 e utilizadas nos experimentos computacionais . . . . .	31
Tabela 2 – Resultados obtidos pelo Gurobi/DE com tempo de execução de 15 minutos	34

## LISTA DE ABREVIATURAS E SIGLAS

ALNS	<i>Adaptive Large Neighborhood Search</i>
B&B	<i>Branch-and-Bound</i>
B&C	<i>Branch-and-Cut</i>
CP	<i>Cutting Plane</i>
DE	Evolução Diferencial, do inglês <i>Differential Evolution</i>
EA	Algoritmos Evolucionários, do inglês <i>Evolutionary Algorithm</i>
GA	Algoritmo Genético, do inglês <i>Genetic Algorithm</i>
GRASP	Procedimento de Busca Adaptativa Gulosa e Randomizada, do inglês <i>Greedy Randomized Adaptive Search Procedure</i>
IEA	Agência Internacional de Energia, do inglês <i>International Energy Agency</i>
ILP	Programação Linear Inteira, do inglês <i>Integer Linear Programming</i>
LP	Programação Linear, do inglês <i>Linear Programming</i>
MILP	Programação Linear Inteira Mista, do inglês <i>Mixed-Integer Linear Programming</i>
RTE	<i>Réseau de Transport d'Électricité</i> , empresa responsável pela operação do sistema de transmissão de energia elétrica na França

## LISTA DE SÍMBOLOS

$T$	número de intervalo de tempo
$H$	horizonte de tempo discreto
$H_i$	conjunto de tempo $t$ permitidos para início de uma intervenção $i \in I$
$C$	conjunto de recursos
$u_{c,t}$	quantidade máxima de recursos
$l_{c,t}$	quantidade mínima de recursos
$I$	intervenções na rede elétrica
$\Delta_{i,t'}$	duração real da intervenção $i \in I$ se ela começa em $t' \in H$
$w_{i,t,t',c}$	carga de trabalho necessária pela intervenção $i \in I$ no instante $t \in H$ , começando no tempo $t' \in H$ com recurso $c \in C$
$S_t$	cenários de risco quantificado pela RTE para o tempo $t \in H$
$r_{i,t,t',s}$	risco em euros para intervenção $i \in I$ no tempo $t \in H$ quando $i$ começa no tempo $t'$ no cenário $s \in S_t$ .
$E$	conjunto de exclusões
$Q_{t,\tau}$	$\tau$ -quantil dos valores de risco no período de tempo $t \in H$
$\alpha$	peso do risco médio na função objetivo
$q_t$	representa o quantil associado no instante $t \in H$
$x_{i,t'}$	variável binária que indica se a intervenção $i \in I$ está configurada para iniciar no tempo $t' \in H_i$
$y_{t,s}$	variável binária que indica se o cenário $s \in S_t$ está entre os cenários de menor risco no instante $t \in H$
$z_t$	variável que corresponde ao risco associado ao cenário de menor risco no instante $t \in H$
$\eta_t$	variável que corresponde ao custo do excesso esperado no momento $t \in H$

## SUMÁRIO

<b>1</b>	<b>INTRODUÇÃO</b>	<b>1</b>
<b>1.1</b>	<b>Objetivo</b>	<b>2</b>
<b>1.2</b>	<b>Contribuições Esperadas</b>	<b>2</b>
<b>1.3</b>	<b>Organização do Texto</b>	<b>3</b>
<b>2</b>	<b>REFERENCIAL TEÓRICO</b>	<b>5</b>
<b>2.1</b>	<b>Problemas de Otimização Combinatória</b>	<b>5</b>
<b>2.1.1</b>	<b>Programação Linear (LP)</b>	<b>6</b>
<b>2.1.2</b>	<b>Programação Linear Inteira (ILP)</b>	<b>6</b>
<b>2.1.3</b>	<b>Programação Linear Inteira Mista (MILP)</b>	<b>7</b>
<b>2.2</b>	<b>Estratégias de Resolução para Problemas de Otimização Combinatória</b>	<b>7</b>
<b>2.2.1</b>	<b>Métodos Exatos</b>	<b>7</b>
<b>2.2.2</b>	<b>Heurísticas e Meta-heurísticas</b>	<b>8</b>
<b>3</b>	<b>DEFINIÇÃO DO PROBLEMA</b>	<b>10</b>
<b>3.1</b>	<b>Entradas e Notações</b>	<b>10</b>
<b>3.1.1</b>	<b>Horizonte de Planejamento</b>	<b>10</b>
<b>3.1.2</b>	<b>Recursos</b>	<b>10</b>
<b>3.2</b>	<b>Intervenções</b>	<b>11</b>
<b>3.3</b>	<b>Risco</b>	<b>11</b>
<b>3.4</b>	<b>Restrições</b>	<b>12</b>
<b>3.4.1</b>	<b>Planejamento Não Preemptivo</b>	<b>12</b>
<b>3.4.2</b>	<b>Restrições de Recursos</b>	<b>12</b>
<b>3.4.3</b>	<b>Restrições de Exclusão</b>	<b>12</b>
<b>3.5</b>	<b>Solução</b>	<b>13</b>
<b>3.6</b>	<b>Objetivo</b>	<b>13</b>
<b>3.6.1</b>	<b>Custo Médio</b>	<b>14</b>
<b>3.6.2</b>	<b>Excesso Esperado</b>	<b>14</b>
<b>3.6.3</b>	<b>Classificação do Planejamento</b>	<b>14</b>
<b>4</b>	<b>REVISÃO DA LITERATURA</b>	<b>16</b>
<b>5</b>	<b>METODOLOGIA</b>	<b>20</b>
<b>5.1</b>	<b>Modelagem do Problema</b>	<b>20</b>

<b>5.2</b>	<b>Estratégia Híbrida para Solução . . . . .</b>	<b>21</b>
<b>5.2.1</b>	<b>Evolução Diferencial (DE) como Estratégia de Refinamento . . . . .</b>	<b>22</b>
<b>5.2.1.1</b>	<b>Mutação (DE/best/1) . . . . .</b>	<b>26</b>
<b>5.2.1.2</b>	<b>Cruzamento Exponencial (/exp) . . . . .</b>	<b>26</b>
<b>5.2.1.3</b>	<b>Seleção . . . . .</b>	<b>28</b>
<b>6</b>	<b>EXPERIMENTOS COMPUTACIONAIS . . . . .</b>	<b>29</b>
<b>6.1</b>	<b>Conjuntos de Instâncias do Problema . . . . .</b>	<b>29</b>
<b>6.2</b>	<b>Ajustes de Parâmetros do DE . . . . .</b>	<b>29</b>
<b>6.3</b>	<b>Infraestrutura Computacional e Softwares . . . . .</b>	<b>30</b>
<b>7</b>	<b>RESULTADOS . . . . .</b>	<b>32</b>
<b>8</b>	<b>CONSIDERAÇÕES FINAIS . . . . .</b>	<b>36</b>
<b>8.1</b>	<b>Conclusões . . . . .</b>	<b>36</b>
<b>8.2</b>	<b>Trabalhos Futuros . . . . .</b>	<b>37</b>
	<b>REFERÊNCIAS . . . . .</b>	<b>38</b>

## 1 INTRODUÇÃO

Nas últimas três décadas, o consumo global de energia elétrica experimentou um crescimento exponencial, impulsionado por fatores como a explosão demográfica, o vigoroso crescimento econômico e os avanços tecnológicos, como a expansão dos *data centers* e o crescente uso da Inteligência Artificial (IA). Segundo dados da Agência Internacional de Energia, do inglês *International Energy Agency* (IEA), o consumo global de eletricidade saltou significativamente, com uma previsão de atingir aproximadamente 30.700 terawatts-hora até 2026, em comparação com níveis bem inferiores registrados nas décadas passadas (INTERNATIONAL ENERGY AGENCY, 2024).

Garantir a entrega eficiente de eletricidade e a manutenção adequada da rede de transmissão e distribuição são responsabilidades centrais dos operadores de redes elétricas. Embora algumas manutenções possam ser realizadas em linhas vivas, onde a rede permanece energizada, há situações em que o desligamento da rede de transmissão é inevitável. Esses desligamentos planejados, embora necessários, podem sobrecarregar outras partes da rede, enfraquecendo o sistema de transmissão. O impacto dessas interrupções planejadas na confiabilidade do sistema pode ser medido em termos de valores de risco (LAM, 2022). Nesses momentos críticos, é importante que o fornecimento de energia elétrica seja assegurado, o que exige um planejamento cuidados das operações na rede.

Este trabalho aborda a otimização do planejamento de manutenções preventivas em redes de transmissão de energia elétrica, utilizando como base o problema proposto no ROADEF/EURO Challenge 2020. Esse desafio foi apresentado pela *Réseau de Transport d'Électricité* (RTE), entidade responsável pela operação do maior sistema de transmissão de alta tensão da Europa, com quase 100.000 km de extensão. O objetivo do ROADEF Challenge é identificar problemas industriais reais e desafiá-los à comunidade de Pesquisa Operacional para que sejam desenvolvidas estratégias inovadoras de resolução.

No contexto do ROADEF/EURO Challenge 2020, a RTE apresenta uma abordagem de planejamento de manutenções preventivas em suas redes de transmissão dividida em três etapas sequenciais. Inicialmente, os valores de risco são calculados para diferentes cenários futuros. Em seguida, esses valores são utilizados em diferentes abordagens de otimização para encontrar um plano de manutenções eficiente. Por fim, uma terceira etapa

valida o planejamento elaborado (RUIZ; TOURNEBISE; RTE, 2020).

O foco deste trabalho, assim como no ROADEF/EURO Challenge 2020, está na segunda etapa dessa abordagem: dado um conjunto de cenários futuros já simulados e com seus respectivos valores de risco, o objetivo é construir um planejamento ótimo que minimize o risco, respeitando todas as restrições de projeto e recursos impostos pelo problema.

## **1.1 Objetivo**

O objetivo geral deste trabalho é projetar e implementar uma estratégia que seja capaz de gerar soluções de boa qualidade para o problema de planejamento de manutenções preventivas em redes de transmissão de energia elétrica proposto pela RTE para o ROADEF/EURO Challenge 2020. Para isso, são considerados os seguintes objetivos específicos:

- Revisar a literatura especializada para identificar o estado da arte em termos de formulação matemática e métodos para solução do problema de manutenção preventiva em redes de transmissão de energia elétrica.
- Modelar o problema de planejamento de manutenções preventivas em redes de transmissão de energia elétrica como um problema de programação linear inteira mista.
- Implementar uma estratégia que seja capaz de gerar soluções de boa qualidade para o problema, visando a minimização do risco associado à operação da rede.
- Validar a eficiência da estratégia implementada por meio de testes computacionais utilizando a mesma base de instâncias propostas para o ROADEF/EURO Challenge 2020, comparando os resultados obtidos com resultados apresentados na competição.

## **1.2 Contribuições Esperadas**

O tema de estudo deste trabalho tem impacto tanto para a comunidade acadêmica quanto para a indústria de energia elétrica. Assim, com a conclusão desse projeto, espera-se as seguintes contribuições:



- Desenvolvimento de um modelo de programação linear inteira mista para o problema de planejamento de manutenções preventivas em redes de transmissão de energia elétrica, considerando a minimização dos indicadores de risco e todas as restrições operacionais, físicas e de recursos apresentados pela RTE.
- Aplicação de Algoritmo Evolucionário como o DE para a obtenção de soluções para o problema de planejamento de manutenções.

### **1.3 Organização do Texto**

Este trabalho está organizado em oito capítulos. No Capítulo 1, foi apresentada a introdução, que traz o contexto do problema, a importância da otimização no planejamento de manutenções preventivas em redes de transmissão de energia elétrica, além de definir o escopo do trabalho.

O Capítulo 2 aborda o referencial teórico, apresentando os fundamentos necessários para a compreensão dos métodos de otimização discutidos ao longo deste trabalho. Esses fundamentos fornecem a base conceitual para as técnicas e abordagens utilizadas.

No Capítulo 3, é realizada a definição formal do problema, incluindo as entradas, restrições e a função objetivo para otimização que orienta o desenvolvimento das soluções propostas.

No Capítulo 4, é feita uma revisão da literatura, onde são revisados estudos e metodologias existentes sobre a otimização de manutenções em redes de transmissão. Este capítulo busca identificar lacunas na literatura e direcionar as decisões para a elaboração da estratégia de solução apresentada.

O Capítulo 5 descreve em detalhes a metodologia adotada, incluindo a modelagem do problema e o desenvolvimento da abordagem híbrida baseada na resolução de uma relaxação combinatória da formulação completa do problema seguida pelo uso do DE como estratégia de refinamento da solução.

No Capítulo 6, são apresentados os experimentos computacionais realizados. Este capítulo apresenta o conjunto de instâncias utilizadas, os ajustes de parâmetros do DE realizados com o irace e a configuração do ambiente de execução dos experimentos, fornecendo uma visão completa da infraestrutura experimental.

O Capítulo 7 apresenta e analisa os resultados obtidos com a estratégia proposta, comparando o desempenho em relação aos resultados oficiais da competição.

Por fim, no Capítulo 8 são feitas as considerações finais, sintetizando os principais pontos abordados ao longo do trabalho. Nesse capítulo, são destacados os resultados alcançados e são sugeridas possíveis direções de continuidade de estudo sobre o tema.

## 2 REFERENCIAL TEÓRICO

Neste capítulo, são apresentadas as definições e fundamentos de otimização combinatória e sua relação com problemas de programação linear inteira, que são de grande relevância na pesquisa operacional e na ciência da computação. Em seguida, são discutidas as metodologias mais comuns para a solução dessa classe de problemas, destacando suas aplicações, vantagens e limitações.

### 2.1 Problemas de Otimização Combinatória

A otimização combinatória é um campo da matemática aplicada que lida com a otimização de problemas em estruturas discretas. Este campo combina técnicas de combinatória, programação linear, e teoria dos algoritmos para resolver problemas que envolvem a seleção de uma melhor solução dentre um conjunto finito, mas geralmente muito grande, de possíveis soluções. Problemas de otimização combinatória surgem em diversas áreas, como logística, finanças, engenharia e telecomunicações, e são conhecidos por sua complexidade computacional (SCHRIJVER; COOK, 1997).

A solução ótima, baseada na maximização ou minimização da função objetivo, pode ser encontrada entre as soluções viáveis. Muitos problemas de otimização combinatória e de relevância prática pertencem à classe de problemas *NP-difíceis* e, portanto, em geral, não são resolvidos de forma eficiente através de técnicas exatas convencionais (LIMA MARTINS; ROSSETI; PLASTINO, 2018).

Um problema de Otimização Combinatória pode ser definido como: dado um conjunto finito  $N = \{1, \dots, n\}$ , pesos  $c_j$  para cada  $j \in N$ , e um conjunto  $F$  de subconjuntos factíveis de  $N$ . O problema de encontrar um subconjunto factível de peso mínimo pode ser expresso da seguinte forma (WOLSEY, 2020):

$$\min_{S \subseteq N} \left\{ \sum_{j \in S} c_j : S \in F \right\} \quad (2.1)$$

Muitas vezes, pode ser formulado como um problema de Programação Inteira ou Programação Inteira 0-1 também chamada de Programação Inteira Binária, que serão definidos nas próximas seções.

### 2.1.1 Programação Linear (LP)

O problema geral de Programação Linear, do inglês *Linear Programming* (LP) é descrito da seguinte forma: dada uma matriz  $A \in \mathbb{R}^{m \times n}$ , e vetores coluna  $b \in \mathbb{R}^m$  e  $c \in \mathbb{R}^n$ , o objetivo é encontrar um vetor coluna  $x \in \mathbb{R}^n$  tal que  $Ax \leq b$  e  $c^T x$  seja ótimo (ou seja, máximo ou mínimo). Aqui,  $c^T x$  denota o produto escalar dos vetores. A notação  $x \leq y$  para vetores  $x$  e  $y$  (de tamanho igual) significa que a desigualdade é válida em cada componente.

Um programa linear é uma instância do problema acima e é frequentemente escrito, sem perda de generalização, como:

$$\min \quad c^T x \quad (2.2)$$

$$\text{s.a.:} \quad Ax \leq b \quad (2.3)$$

$$x \geq 0, \quad (2.4)$$

Uma solução viável de uma LP acima é um vetor  $x$  tal que  $Ax \leq b$  é satisfeito. A solução viável  $x$  que atinge o mínimo para  $C^T x$  é chamada de solução ótima.

### 2.1.2 Programação Linear Inteira (ILP)

Se todas as variáveis de um problema de LP forem inteiras, temos um problema de Programação Linear Inteira, do inglês *Integer Linear Programming* (ILP). A formulação de um problema de PLI é escrita como:

$$\min \quad c^T x \quad (2.5)$$

$$\text{s.a.:} \quad Ax \leq b \quad (2.6)$$

$$x \geq 0 \quad \text{é inteiro}, \quad (2.7)$$

Um caso especial de ILP é quando todas as variáveis de decisão estão restritas aos valores  $\{0, 1\}$ . Nesse caso, o problema é denominado como um problema de Programação

Linear Inteira Binária ou Programação Linear Inteira 0-1, que pode ser descrito como:

$$\min \quad c^T x \quad (2.8)$$

$$\text{s.a.:} \quad Ax \leq b \quad (2.9)$$

$$x \in \{0, 1\}^n. \quad (2.10)$$

### 2.1.3 Programação Linear Inteira Mista (MILP)

Quando algumas, mas não todas, variáveis de decisão são inteiras, temos um Programa Linear Inteiro Misto (MILP), que pode ser escrito como:

$$\min \quad c^T x + h^T y \quad (2.11)$$

$$\text{s.a.:} \quad Ax + Gy \leq b \quad (2.12)$$

$$x \geq 0 \quad \text{é inteiro}, \quad (2.13)$$

$$y \geq 0. \quad (2.14)$$

Note que o problema é definido sobre dois vetores de variáveis de decisão,  $x$  que são as variáveis restritas a valores inteiros e  $y$  que podem assumir valores reais.

## 2.2 Estratégias de Resolução para Problemas de Otimização Combinatória

Resolver problemas de otimização combinatória é desafiador, especialmente devido à sua complexidade computacional, muitas vezes classificada como *NP-difícil*. Para lidar com esses desafios, uma variedade de estratégias foi desenvolvida, dentre as quais podemos citar os métodos exatos, as heurísticas e meta-heurísticas.

### 2.2.1 Métodos Exatos

Os algoritmos exatos garantem a obtenção da solução ótima para problemas de otimização. Geralmente, estes algoritmos definem estratégias iterativas que resolvem subproblemas obtidos a partir de relaxações do problema original, limitando o espaço de busca a cada iteração, até que a solução ótima seja encontrada (SILVA, 2014). Alguns

dos algoritmos exatos mais conhecidos na literatura são o algoritmo de *Branch-and-Bound* (B&B) e o algoritmo *Cutting Plane* (CP).

O algoritmo B&B utiliza uma estratégia de divisão e conquista, explorando implicitamente todas as soluções viáveis através de uma árvore de busca. Isso é possível com o uso de limites inferiores e limites superiores que permitem eliminar ramificações da árvore de busca que se têm certeza de que não contêm a solução ótima.

Já os métodos de planos de corte são algoritmos exatos que resolvem uma sequência de relaxações lineares do problema de programação inteira. As relaxações são gradualmente aprimoradas, através da introdução de novas restrições, para fornecer melhores aproximações ao problema de programação inteira original, pelo menos na vizinhança da solução ótima. Esses métodos têm se mostrado extremamente úteis computacionalmente, especialmente quando combinados com o algoritmo de B&B em um *framework* denominado *Branch-and-Cut* (B&C). Para instâncias difíceis que não podem ser resolvidas até a otimalidade, os algoritmos de planos de corte podem produzir aproximações da solução ótima em tempos de computação moderados, com garantias sobre a distância à otimalidade (MITCHELL, 2009).

Apesar dos algoritmos exatos garantirem a solução ótima para os problemas que se propõem a resolver, eles geralmente demandam uma complexidade de tempo exponencial, tornando-se estratégias inviáveis para problemas de grandes dimensões (BERTSIMAS; TSITSIKLIS, 1997). O problema geral de programação linear inteira mista é um problema pertencente à classe de problemas *NP-difícil* (KORTE; VYGEN, 2018).

### 2.2.2 Heurísticas e Meta-heurísticas

As heurísticas tornaram-se uma família muito popular de métodos de solução para problemas de otimização porque tendem a encontrar soluções aceitáveis em um tempo razoável. A palavra heurística significa “servir para descobrir” ou “encontrar”. É uma formação irregular do termo grego *heuretikos*, que significa “inventivo”. Está relacionada à palavra grega *heuriskein*, que significa “encontrar”, e à palavra *Eureka*, que vem do grego antigo *eurika*, que significa “eu encontrei” (MARTÍ; PARDALOS; RESENDE, 2018).

Nas últimas décadas, avanços algorítmicos, bem como melhorias em *hardware* e *software*, proporcionaram um excelente ambiente para construir sistemas de suporte à

decisão baseados em heurísticas, utilizando metodologias novas e eficazes. Para o leigo, heurísticas podem ser vistas como regras práticas, mas, apesar de sua imprecisão, o campo das heurísticas é muito rico e refere-se a técnicas baseadas na experiência para resolução de problemas, aprendizado e descoberta. Qualquer solução heurística dada não é garantida como ótima, mas os métodos heurísticos são usados para acelerar o processo de encontrar soluções satisfatórias onde métodos exatos são impraticáveis devido à complexidade computacional para encontrar e provar a otimalidade de uma solução (MARTÍ; PARDALOS; RESENDE, 2018).

As heurísticas são específicas para um problema, de modo que um método que funciona para um problema pode não ser viável para resolver outro problema diferente. Em contraste, as meta-heurísticas são técnicas poderosas geralmente aplicáveis a um grande número de problemas. Uma meta-heurística refere-se a uma estratégia mestra que orienta e modifica as operações de heurísticas subordinadas, combinando inteligentemente diferentes conceitos para explorar o espaço de busca (EHRGOTT; GANDIBLEUX, 2000).

Na literatura, há uma variedade de meta-heurísticas, como Algoritmo Genético, *Simulated Annealing*, *Tabu Search*, *Variable Neighborhood Search*, *Iterated Local Search*, *GRASP*, *Large Neighborhood Search*, entre outros (GENDREAU; POTVIN, 2019).

Essas meta-heurísticas combinam técnicas de diversificação e intensificação para explorar eficientemente o espaço de soluções em problemas de otimização combinatória. A diversificação visa explorar o espaço de soluções através de diferentes técnicas que permitem sair de regiões de atração de soluções sub-ótimas para descobrir novas áreas promissoras. A intensificação, por sua vez foca na busca da vizinhança de uma região promissora, refinando e melhorando as soluções atuais. Ao equilibrar a exploração global com a exploração local, as meta-heurísticas aumentam as chances de encontrar soluções ótimas ou quase ótimas, evitando a estagnação em regiões de mínimo local.

### 3 DEFINIÇÃO DO PROBLEMA

Neste capítulo é definido o problema de planejamento de manutenções preventivas em redes de transmissão de energia elétrica, proposto pela *Réseau de Transport d'Électricité* (RTE) para o ROADEF/EURO Challenge 2020. Nas seções seguintes são apresentadas as entradas do problema e a notação adotada, a definição da solução esperada, as restrições do problema e a função objetivo.

#### 3.1 Entradas e Notações

##### 3.1.1 Horizonte de Planejamento

O planejamento precisa ser estabelecido ao longo de um ano. No entanto, o intervalo de tempo pode ser diário ou semanal, dependendo da precisão necessária. O número de intervalos de tempo é denotado por  $T \in \mathbb{N}$  e o horizonte de tempo discreto é denotado por  $H = \{1, \dots, T\}$ . Por exemplo, para um planejamento diário temos  $T = 365$  e para um planejamento semanal temos  $T = 52$ .

##### 3.1.2 Recursos

Para realizar as intervenções, é necessária mão de obra organizada em equipes de diferentes tamanhos e habilidades específicas. Cada equipe pode ser necessária em qualquer intervenção. Assim, essas equipes são consideradas recursos necessários para a realização das intervenções. Denotamos por  $C$  esse conjunto de recursos.

Os recursos disponíveis são sempre limitados e, portanto, há um valor máximo para cada recurso e que não pode ser excedido. Além disso, a força de trabalho disponível varia com o tempo. Portanto, para cada recurso  $c \in C$  e cada etapa de tempo  $t \in H$ ,  $u_{c,t}$  denota o limite superior.

Por motivos operacionais, há também um limite inferior para o uso de recursos. Para evitar que a força de trabalho não seja utilizada, existem limites que indicam o valor mínimo necessário dos recursos utilizados. Esse limite é denotado por  $l_{c,t}$  e representa o valor mínimo para o recurso  $c \in C$  no tempo  $t \in H$ .



### 3.2 Intervenções

As intervenções são tarefas de manutenção preventiva que devem ser planejadas para o ano (horizonte de planejamento). Elas não são iguais em termos de duração nem em termos de necessidade de recursos. O conjunto de intervenções é denotado por  $I$ .

Por conta dos finais de semana e feriados, a duração de uma determinada intervenção depende de quando ela começa. Portanto,  $\Delta_{i,t'} \in \mathbb{N}$  denota a duração real da intervenção  $i \in I$  se ela começa no tempo  $t' \in H$ .

Cada intervenção exige habilidades específicas para ser realizada corretamente. Consequentemente, a carga de trabalho de recursos depende tanto do tipo de recurso quanto do tempo. Isso ocorre porque a duração de uma intervenção está relacionada ao tempo, e geralmente são necessários mais recursos no início e no final da intervenção para atividades específicas (como transporte de equipamentos e retoques finais). Assim, a quantidade necessária de um recurso  $c \in C$  no tempo  $t \in H$  pela intervenção  $i \in I$ , caso  $i$  comece no tempo  $t' \in H$ , é denotada por  $w_{i,t,t',c} \in \mathbb{R}^+$ .

### 3.3 Risco

Durante a realização de uma intervenção, as linhas envolvidas precisam ser desconectadas, o que enfraquece a rede elétrica. Isso acarreta um risco para a RTE, pois, em caso de falha em um ponto próximo (devido a condições climáticas extremas por exemplo), a rede pode não conseguir atender adequadamente à demanda elétrica. Embora a probabilidade desses eventos seja muito baixa, eles devem ser considerados no planejamento. Para quantificar financeiramente esses riscos, a RTE já realizou simulações para diversos cenários em diferentes intervalos de tempo. Esses cenários correspondem a uma determinada operação da rede e não dependem das intervenções. No entanto, o valor do risco em si depende da intervenção considerada e também do tempo, já que geralmente é menos arriscado realizar intervenções no verão (quando a rede elétrica não é tão solicitada) do que no inverno. Seja  $S_t$  o conjunto de cenários simulados para o tempo  $t \in H$ . Portanto, o valor do risco (em euros) é denotado por  $r_{i,t,t',s} \in \mathbb{R}$  para o período de tempo  $t \in H$ , cenário  $s \in S_t$ , e intervenção  $i \in I$ , quando  $i$  começa no tempo  $t' \in H$ .

### 3.4 Restrições

#### 3.4.1 Planejamento Não Preemptivo

Todas as intervenções devem ser executadas dentro do período de um ano. Assim, todas as intervenções devem ser concluídas até o final do horizonte de planejamento. Se a intervenção  $i \in I$  começar no tempo  $t' \in H$ , então  $t' + \Delta_{i,t'} \leq T + 1$ .

Além disso, uma vez que as intervenções exigem o desligamento de algumas linhas da rede elétrica, elas não podem ser interrompidas uma vez iniciadas (exceto em dias não úteis). Mais precisamente, se a intervenção  $i \in I$  começar no tempo  $t' \in H$ , ela deve terminar em  $t' + \Delta_{i,t'}$ .

#### 3.4.2 Restrições de Recursos

Seja  $t' \in H$  o tempo de início da intervenção  $i \in I$ , a carga de trabalho devida à intervenção  $i$  para o recurso  $c$  no tempo  $t$  é  $w_{i,t,t',c}$ . A carga de trabalho total do recurso  $c$  no tempo  $t$  é, então:

$$w_{c,t} = \sum_{i \in I_t} r_{i,t,t',c} \quad (3.1)$$

Como os recursos necessários não podem exceder a capacidade máxima de recursos disponíveis e devem ser pelo menos iguais à carga de trabalho mínima, então:

$$l_{c,t} \leq w_{c,t} \leq u_{c,t} \quad \forall c \in C, t \in H \quad (3.2)$$

#### 3.4.3 Restrições de Exclusão

Algumas linhas de manutenção estão muito próximas, impossibilitando intervenções simultâneas, o que enfraqueceria a rede e seria desastroso se outra linha próxima fosse desconectada. Embora os riscos sejam calculados individualmente, as exclusões consideram essas dependências e variam com o tempo. Por exemplo, no verão, é menos arriscado enfraquecer a rede devido à menor demanda em comparação com o inverno.

O conjunto de exclusões denotado por  $E$  trata-se de tuplas  $(i, j, t)$ , onde  $i, j \in I$  e


$t \in H$ , indicando que as intervenções  $i$  e  $j$  não podem ser executadas simultaneamente no tempo  $t$ . As restrições de exclusão podem ser escritas como:

$$i \in I_t \Rightarrow j \notin I_t \quad \forall (i, j, t) \in E \quad (3.3)$$

### 3.5 Solução

Uma solução candidata para esse problema é um planeamento da execução das intervenções ao longo do horizonte de planeamento. Assim uma solução pode ser representada por uma lista  $L$  de pares  $(i, t') \in I \times H$ , onde  $t'$  é o tempo de início da intervenção  $i$ . Um planeamento é considerado factível se, todas as restrições apresentadas na Seção 3.4 forem atendidas.

Figura 1 – Exemplo de uma solução factível



Fonte: (RUIZ; TOURNEBISE; RTE, 2020)

### 3.6 Objetivo

A avaliação da qualidade de um planeamento factível depende de dois indicadores principais: o custo médio e o excesso esperado, ambos quantificados em euros.

### 3.6.1 Custo Médio

O custo médio considera o risco acumulado ao longo do horizonte de planejamento. O risco acumulado em um determinado período de tempo  $t$  para um cenário  $s$ , denotado por  $r_{t,s}$ , é a soma dos riscos nos cenários sobre as intervenções em andamento no tempo  $t$ . O risco acumulado médio em  $t$  é dado por:

$$\bar{r}_t = \frac{1}{|S_t|} \sum_{s \in S_t} r_{t,s} \quad (3.4)$$

e, com isso, o risco total do planejamento (ou custo médio) é dado por:

$$obj_1 = \frac{1}{T} \sum_{t \in H} \bar{r}_t \quad (3.5)$$

### 3.6.2 Excesso Esperado

O excesso esperado considera a variabilidade do custo ao longo dos cenários, especialmente focando em cenários críticos com custos extremamente altos. Para determinar o excesso esperado, são dados os valores  $Q_{t,\tau}$  para cada período  $t \in H$ , que é o  $\tau$ -quantil dos valores de risco no período  $t$ . A partir disso, o excesso no tempo  $t$  é calculado como:

$$Excesso_\tau(t) = \max(0, Q_{t,\tau} - \bar{r}_t) \quad (3.6)$$

Por fim, o excesso esperado total do planejamento é dado por:

$$obj_2(\tau) = \frac{1}{T} \sum_{t \in H} Excesso_\tau(t) \quad (3.7)$$

### 3.6.3 Classificação do Planejamento

Os dois indicadores (custo médio e excesso esperado) são combinados usando um fator de escala predefinido  $\alpha$  que reflete a aversão ao risco. Dessa forma, a função objetivo

final é minimizar a seguinte expressão:

$$obj(\tau) = \alpha \times obj_1 + (1 - \alpha) \times obj_2(\tau) \quad (3.8)$$

O objetivo é encontrar um planeamento factível que considera a minimização tanto do custo médio quanto o excesso esperado para refletir a qualidade e a robustez do planeamento frente os diferentes cenários de risco.

## 4 REVISÃO DA LITERATURA

O desafio proposto pela ROADEF/EURO Challenge 2020 destaca a complexidade envolvida no planejamento de manutenções em redes de transmissão de energia elétrica, onde a segurança e a eficiência do sistema dependem de um planejamento cuidadoso. Este planejamento deve considerar fatores críticos como a incerteza na geração de energia, restrições operacionais e a necessidade de minimizar riscos de falhas. A otimização do planejamento de manutenções em um ambiente sujeito a incertezas é, portanto, uma tarefa desafiadora, exigindo soluções que equilibrem múltiplos critérios. Nesse contexto, abordagens heurísticas têm se mostrado promissoras para a resolução de problemas de alta complexidade computacional, oferecendo soluções eficazes e adaptativas. Esta seção revisa a literatura existente, com ênfase em contribuições recentes sobre o planejamento de manutenções em redes de transmissão de energia, abordando a incorporação de incertezas e a aplicação de métodos heurísticos.

Crognier et al. (2021) discutem os desafios emergentes no planejamento de manutenção em redes de transmissão de energia, especialmente no contexto da transição energética, marcada pela crescente integração de fontes renováveis. Os autores apontam que as práticas de manutenção tradicionais podem se tornar insuficientes à medida que aumenta a participação de energias renováveis, introduzindo novas incertezas e restrições operacionais. A revisão da literatura mostra que a maioria dos estudos existentes foca no planejamento de manutenção de unidades geradoras, raramente abordando as especificidades das redes de transmissão. Poucos trabalhos consideram explicitamente o impacto da transição energética no planejamento de manutenção. A principal contribuição do trabalho de Crognier et al. (2021) é a proposta de uma nova metodologia que incorpora a incerteza na operação da rede ao planejar manutenções, oferecendo uma abordagem robusta e aplicável a diferentes cenários futuros, assegurando a viabilidade das práticas de manutenção a longo prazo.

Gouvine (2021) apresenta uma abordagem diferente para resolver o problema de planejamento de manutenção na rede elétrica operada pela RTE. O trabalho combina geração de restrições com uma nova família de planos de corte para lidar com a não convexidade do problema, especialmente ao utilizar a função quantil em problemas de programação estocástica. A pesquisa demonstra como essas melhorias podem impactar

a resolução de problemas envolvendo modelagem de incertezas, mostrando ganhos substanciais em instâncias reais. A função quantil, discutida em estudos anteriores, é utilizada aqui para penalizar cenários de pior caso, tornando o problema de planejamento mais complexo e demandando soluções avançadas, discutidas por (BELDICEANU, 2001) e (CODATO; FISCHETTI, 2006). A metodologia proposta por Gouvine (2021) inclui a aplicação de técnicas de relaxação poliedral e métodos de geração de restrições, que melhoram significativamente os limites inferiores e superiores, reduzindo o tempo de solução e otimizando os resultados para as instâncias de grande porte.

Lam (2022) discutem a aplicação de métodos de otimização combinatória para resolver problemas complexos de planejamento de manutenção sob incerteza, abordando a modelagem de incertezas no tempo de manutenção e o uso de meta-heurísticas para gerar soluções eficientes. O trabalho propõe modelos matemáticos e algoritmos de otimização, como Algoritmos Genéticos e *Iterated Local Search*, aplicados em três cenários distintos: manutenção de material rodante, planejamento de trabalhos que compartilham múltiplos recursos e planejamento de manutenção em redes de distribuição de energia. A pesquisa destaca a importância de considerar as incertezas nos processos de manutenção para evitar planos não realistas que possam gerar custos elevados e interrupções nas operações. As abordagens híbridas propostas combinam técnicas heurísticas com métodos de amostragem, resultando em soluções robustas e práticas.

Woller, Rada e Kulich (2023) aplicam a meta-heurística *Adaptive Large Neighborhood Search* (ALNS) ao problema de planejamento de manutenção de transmissão em redes elétricas. O artigo destaca a complexidade do planejamento devido às suas propriedades temporais, restrições e uma função objetivo não linear baseada em quantil. O trabalho compara o planejamento de manutenções em redes elétricas com o problema de planejamento de manutenção nas geradoras de energia elétrica e propõe novos operadores de destruição e reparo do ALNS específicos para abordar a variante de planejamento apresentada na competição ROADEF/EURO Challenge 2020. A abordagem ALNS mostrou-se eficaz ao explorar vizinhanças diversificadas de soluções e evitar a convergência prematura, resultando em desempenho consistente nos diferentes conjuntos de instâncias da competição. O artigo também analisa o impacto da hibridização dos operadores de reparo e das extensões do algoritmo, como a introdução de busca local e penalização estática de violações de restrições, contribuindo

significativamente para a solução de problemas de otimização combinatória.

Vasquez, Buljubasic e Hanafi (2023) apresentam uma nova meta-heurística de penalização de cenários para resolver problemas de planejamento estocástico. O estudo baseia-se em abordagens clássicas de otimização, como o modelo de média-variância de (MARKOWITZ, 1952), amplamente utilizado na análise de risco financeiro, mas que apresenta limitações ao não ser consistente com as regras de dominância estocástica, conforme apontado por (OGRYCZAK; RUSZCZYNSKI, 2002). Para superar essas limitações, a pesquisa adota quantis como medida de risco, especificamente a métrica de *Value at Risk* (VAR). O problema abordado é também inspirado no desafio prático do RTE no contexto do ROADEF/EURO Challenge 2020, modelado como um problema de programação não-linear inteira mista. Devido à complexidade computacional, o estudo utiliza métodos heurísticos e meta-heurísticos, incluindo a abordagem de “ghost image” proposta por (GLOVER, 1994), e discute estratégias híbridas como a decomposição de Benders. Os resultados experimentais demonstram a eficácia da meta-heurística proposta em resolver instâncias grandes fornecidas pela RTE, destacando a relevância prática da abordagem na otimização de políticas de manutenção em redes de transmissão elétrica.

Gu et al. (2023) também exploram o problema de planejamento de manutenção em redes de transmissão de energia elétrica, conforme apresentado no desafio ROADEF/EURO Challenge 2020. O estudo aborda a complexidade de programar interrupções necessárias para a manutenção, considerando as limitações de recursos e a incerteza nas operações de manutenção, caracterizada pelos valores de risco fornecidos pelo operador da rede. Diversas abordagens foram avaliadas com base nas instâncias da competição, destacando-se uma heurística baseada no *Iterated Local Search* com perturbação auto-adaptativa, que se mostrou a mais eficaz entre as abordagens testadas.

Parreño, Parreño-Torres e Alvarez-Valdes (2023) investigam o problema de planejamento de manutenção no sistema de transmissão de eletricidade, abordando as complexidades na avaliação de riscos e na otimização do cronograma de manutenção, também utilizando o desafio proposto pela ROADEF/EURO Challenge 2020. O trabalho destaca a importância da confiabilidade e da gestão de riscos, alinhando-se com a literatura existente que utiliza métricas de confiabilidade como SAIFI, SAIDI e AENS para avaliar o desempenho do sistema de energia. Diferencia-se ao adotar a estratégia da RTE, que separa a avaliação de risco do planejamento das operações de manutenção,



utilizando modelos matemáticos combinados com algoritmos heurísticos para obtenção de soluções.

Cattaruzza et al. (2024) exploram técnicas de otimização para problemas de minimização de quantis em contextos mistos e inteiros, com foco em desafios como o ROADEF/EURO Challenge 2020 e a otimização de portfólios. O trabalho discute a aplicação de formulações de restrições de chance, propostas para diversos contextos, incluindo o projeto de redes confiáveis e a alocação de recursos em cenários incertos. Os autores desenvolvem desigualdades válidas derivadas da teoria da dualidade, utilizadas para melhorar as formulações dos problemas escritos como MILP. Técnicas como o Método de Direção Alternada Sobreposta e o Agrupamento Adaptativo de Cenários são apresentadas como abordagens eficientes para resolver problemas de larga escala, combinando a capacidade de encontrar soluções ótimas com a redução do tempo computacional necessário, especialmente em contextos desafiadores como os propostos no desafio ROADEF/EURO Challenge 2020.

Os estudos citados acima abordam diferentes metodologias e técnicas de otimização, desde programação matemática a algoritmos heurísticos. Em particular, os estudos focados na aplicação de técnicas de otimização no contexto da ROADEF/EURO Challenge 2020 fornecem uma base sólida para o desenvolvimento do presente trabalho, que busca projetar e implementar uma estratégia híbrida, utilizando um modelo de programação linear inteira e o algoritmo DE como técnica de refinamento para a otimização do problema de planejamento de manutenções preventivas em redes de transmissão de energia elétrica.

## 5 METODOLOGIA

Neste capítulo, apresenta-se a metodologia adotada para resolver o problema de planejamento de manutenções em redes de transmissão de energia elétrica, como apresentado pelo ROADEF/EURO Challenge 2020. Inicialmente, é detalhada a modelagem matemática do problema. Em seguida, é descrito a estratégia de solução proposta.

### 5.1 Modelagem do Problema

Considere  $H_i = \{1, \dots, t_{max}^i\}$  como o conjunto de tempos  $t$  permitidos para o início de uma intervenção  $i \in I$ ; seja  $r_{i,t,t',s} \geq 0$  o custo relacionado ao risco no momento  $t \in H$  em um cenário  $s \in S_t$  se a intervenção  $i \in I$  começar em  $t' \in H_i$ ;  $w_{i,t,t',c}$  como a quantidade de recurso  $c \in C$  necessária no momento  $t \in H$  pela intervenção  $i \in I$  se esta intervenção começar no momento  $t' \in H_i$ ;  $u_{c,t}$  e  $l_{c,t}$  são, respectivamente, os limites superior e inferior do recurso  $c \in C$  disponível/requerido no momento  $t \in H$ ;  $\Delta_{i,t'}$  é a duração da intervenção  $i$  iniciada no tempo  $t'$ ;  $E$  é o conjunto de restrições de exclusão entre as intervenções;  $\alpha \in [0, 1]$  o peso do risco médio na função objetivo;  $q_t$  representa o quantil associado ao instante  $t \in H$ .

Considere também as variáveis de decisão:

- $x_{i,t'} \in \{0, 1\}$ , uma variável binária que assume o valor 1 se a intervenção  $i \in I$  for configurada para iniciar no momento  $t' \in H_i$ , e 0 (zero) caso contrário;
- $y_{t,s} \in \{0, 1\}$ , uma variável binária que assume o valor 1 se cenário  $s \in S_t$  esteja entre os cenários de menor risco no instante  $t$ , e 0 (zero) caso contrário;
- $z_t$ , uma variável que corresponde ao risco associado ao cenário de menor risco no instante  $t \in H$ ;
- $\eta_t \geq 0$ , uma variável que representa o custo do excesso esperado no momento  $t \in H$ .

Dessa forma, podemos escrever o problema de planejamento de manutenção na rede elétrica como um problema de programação linear:

$$\min \quad \alpha \sum_{t \in H} \sum_{s \in S_t} \sum_{i \in I} \sum_{t' \in H_i} \frac{r_{i,t,t',s}}{T|S_t|} x_{i,t'} + \frac{1-\alpha}{T} \sum_{t \in H} \eta_t \quad (5.1)$$

$$\text{s.a.: } \sum_{t' \in H_i} x_{i,t'} = 1 \quad \forall i \in I \quad (5.2)$$

$$\sum_{i \in I} \sum_{t' \in H_i} w_{i,t,t',c} x_{i,t'} \leq u_{c,t} \quad \forall c \in C; t \in H \quad (5.3)$$

$$\sum_{i \in I} \sum_{t' \in H_i} w_{i,t,t',c} x_{i,t'} \geq l_{c,t} \quad \forall c \in C; t \in H \quad (5.4)$$

$$\sum_{\substack{t' \in H_i: \\ t' \leq t; \\ t \leq t' + \Delta_{i,t'} - 1}} x_{i,t'} + \sum_{\substack{t' \in H_j: \\ t' \leq t; \\ t \leq t' + \Delta_{j,t'} - 1}} x_{j,t'} \leq 1 \quad \forall (i, j, t) \in E \quad (5.5)$$

$$\sum_{s \in S_t} y_{t,s} \geq q_t \quad (5.6)$$

$$z_t \geq \sum_{i \in I} \sum_{t' \in H_i} r_{i,t,t',s} x_{i,t'} - M_{t,s} (1 - y_{t,s}) \quad \forall s \in S_t \quad (5.7)$$

$$\eta_t \geq z_t - \frac{1}{|S_t|} \sum_{s \in S_t} \sum_{i \in I} \sum_{t' \in H_i} r_{i,t,t',s} x_{i,t'} \quad \forall s \in S_t \quad (5.8)$$

$$x_{i,t'} \in \{0, 1\} \quad \forall i \in I; t' \in H_i \quad (5.9)$$

$$y_{t,s} \in \{0, 1\} \quad \forall s \in S_t \quad (5.10)$$

$$z_t \geq 0 \quad \forall t \in H \quad (5.11)$$

$$\eta_t \geq 0 \quad \forall t \in H \quad (5.12)$$

A formulação acima define o tempo de início de cada intervenção, garantindo que as restrições de agendamento (5.2), recursos (5.3)–(5.4) e disjuntivas (5.5) sejam atendidas. Em (5.9)–(5.12) é definido o domínio das variáveis de decisão.

Ao resolver apenas o problema (5.2) - (5.5) e (5.9) obtém-se uma solução factível. No entanto, essa solução não é necessariamente a solução ótima, a não ser que o excesso esperado seja zero.

## 5.2 Estratégia Híbrida para Solução

Para resolver o problema de planeamento de manutenção em redes de transmissão de energia eléctrica, proposto no ROADEF/EURO Challenge 2020, foi decidido utilizar uma abordagem híbrida resolvendo inicialmente uma relaxação combinatória do problema, onde apenas as restrições (5.2)–(5.5) e (5.9) são

consideradas. Em seguida o DE é utilizado para melhorar a solução.

Para resolver a relaxação combinatória, foi utilizado o *solver* Gurobi: o *Gurobi Optimizer* (frequentemente referido simplesmente como "*Gurobi*") é um *solver* de otimização amplamente reconhecido no mercado, desenvolvido pela *Gurobi Optimization, LLC*. Esse *solver* utiliza o B&C, além de heurísticas, para resolver problemas de otimização.

O uso do Gurobi foi necessário devido à alta complexidade do problema. Para instâncias muito grandes, não foi possível encontrar uma solução factível que respeitasse todas as restrições no limite de tempo de 15 minutos utilizado na competição. Por essa razão, optou-se por desconsiderar o excesso esperado. Embora essa abordagem não garanta a obtenção da solução ótima, ela assegura que a solução encontrada seja factível.

### 5.2.1 Evolução Diferencial (DE) como Estratégia de Refinamento

O DE é uma meta-heurística originalmente apresentada como uma técnica relacionada à família de *Algoritmos Evolucionários*, eficaz para problemas de otimização não-linear de espaço contínuo. Apesar de sua simplicidade, o DE demonstra ser eficiente. Ainda que exija poucos parâmetros de controle e apenas operações aritméticas elementares, o DE é capaz de convergir para regiões promissoras do espaço de busca e, em muitas classes de problemas, chegar até mesmo à solução ótima (STORN; PRICE, 1997).

Semelhante a outras meta-heurísticas evolucionárias, o DE busca resolver o problema por meio da amostragem iterativa de um conjunto finito de soluções. A cada iteração, a função de amostragem — implicitamente representada pelos operadores de mutação e cruzamento — é ajustada com base nos resultados obtidos, direcionando a exploração para as regiões mais promissoras em termos de valores objetivos.

Tal como acontece com todos os EA, o DE trabalha com conjunto de soluções denominado população, e não com uma única solução. A população  $P_x$  contém, a cada interação  $g$ , denominada geração,  $Np$  soluções candidatas, codificadas como vetores, em que, para cada vetor, a  $i$ -ésima posição contém o tempo de início da intervenção  $i \in I$ :

$$P_{x,g} = (x_{i,g}), \quad i = 0, 1, \dots, Np - 1, \quad g = 0, 1, \dots, g_{max} \quad (5.13)$$

$$x_{i,g} = (x_{j,i,g}), \quad j = 0, 1, \dots, |I| - 1 \quad (5.14)$$

Para iniciar a busca, é necessário inicializar a população. Geralmente, quando não se dispõe de informações adicionais sobre a localização do ótimo global além dos limites das variáveis do problema, a abordagem mais natural é semear a população inicial  $P_{x,g=0}$  com valores aleatórios dentro das restrições fornecidas. No caso específico do problema esses indivíduos representam intervenções e seus respectivos tempos de início no horizonte de tempo, e são gerados aleatoriamente dentro dos limites inferiores e superiores estabelecidos para cada intervenção.

$$P_{x,g=0} = x_{j,i,0} = rand_j(0, 1) \times (b_{j,U} - b_{j,L}) + b_{j,L} \quad \forall i \in [0, Np - 1]; \forall j \in [0, |I| - 1] \quad (5.15)$$

onde  $b_L$  e  $b_U$  representam os vetores de limite inferiores e superiores  $L$  e  $U$  respectivamente. Aqui,  $rand_j(0, 1)$  representa um valor aleatório uniformemente distribuído que varia entre  $[0, 1)$ . Como as variáveis no problema são inteiras, os valores gerados para os indivíduos da população são arredondados durante a inicialização. A solução obtida na primeira etapa, pelo Gurobi, é inserida na população inicial para que o DE realize o refinamento. O Algoritmo 1 apresenta o pseudo-código do DE.

---

**Algoritmo 1:** Pseudo-código do algoritmo Evolução Diferencial (DE)
 

---

**Entrada:**  $f(\cdot) : \mathbb{R}^n \mapsto \mathbb{R}$ : função objetivo

**Entrada:**  $N_p$ : tamanho da população

**Entrada:**  $F$  : fator de mutação

**Entrada:**  $Cr$ : fator de cruzamento

- 1 Inicializa vetores da população  $P_{x,0} = (x_{i,0}), \quad i = 0, 1, \dots, N_p - 1;$
- 2  $g \leftarrow 0$
- 3 **repita**
- 4   **para**  $i \leftarrow 0$  **até**  $N_p - 1$  **faça**
- 5     Criar vetor mutante (*/best/1*)  $v_{i,g}$  ; // Equação 5.16
- 6     Criar vetor de teste (*/exp*)  $u_{i,g}$  ; // Algoritmo 2
- 7     **se**  $f(u_{i,g}) \leq f(x_{i,g})$  **então**
- 8        $x_{i,g+1} \leftarrow u_{i,g};$
- 9     **fim**
- 10    **senão**
- 11      $x_{i,g+1} \leftarrow x_{i,g};$
- 12    **fim**
- 13   **fim**
- 14    $g \leftarrow g + 1;$  ; // Próxima geração
- 15 **até** critério de parada satisfeito;
- 16 **retorna** Melhor solução  $x_{i,g}$  encontrada

---

Durante o processo de avaliação dos indivíduos da população, aqueles que violam as restrições são penalizados, e a penalidade é adicionada ao valor da função objetivo. Dessa forma, no pior cenário, a solução retornada pelo DE corresponde àquela encontrada pelo Gurobi, que, conforme apresentado na Seção 5.2, é garantidamente uma solução factível.

O critério de parada do algoritmo é baseado no limite máximo de 15 minutos de execução estabelecido pela competição. Para lidar com a possibilidade de o algoritmo ficar preso em mínimos locais, foi implementada uma estratégia de renovação da população. A cada 100 gerações sem melhorias, uma nova população é gerada, mantendo apenas o melhor indivíduo da geração anterior, conforme a Eq. (5.15).

O DE é um algoritmo que opera por meio de um ciclo simples de estágios. Neste

trabalho, um aspecto relevante é destacado na Figura 2: durante a etapa de criação da população inicial, é incorporado um indivíduo viável gerado pelo Gurobi. Essa modificação é importante, pois, devido à natureza e à complexidade do problema, o DE apresentou dificuldades para encontrar soluções factíveis, dentro do limite de tempo de 15 minutos, para instâncias de grande porte.

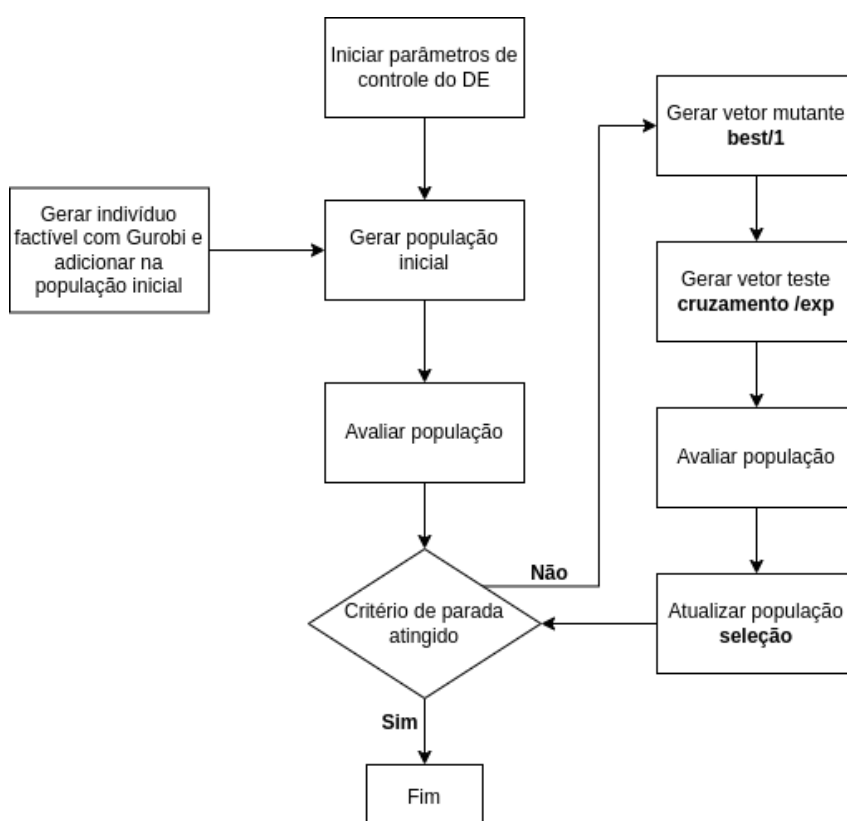


Figura 2 – Fluxograma da estratégia híbrida Gurobi/DE

Outro ponto relevante a destacar é que o DE é um algoritmo que pode ser executado em paralelo. No entanto, neste trabalho, devido às limitações do *Python*, linguagem utilizada na implementação, não foi possível aproveitar o processamento paralelo na execução do DE. Isso ocorre porque o paralelismo no *Python* é mais adequado para tarefas do tipo *I/O-bound*.

A seguir, é brevemente discutido os outros três operadores utilizados com o DE: mutação, cruzamento e seleção.

### 5.2.1.1 Mutação (DE/best/1)

Na literatura é encontrado diversas estratégias para gerar o vetor mutante. Para este trabalho, após realizar testes com a estratégia **DE/rand/1** e **DE/best/1**, optou-se pela segunda opção já que ela demonstrou ser mais eficiente, pois utiliza o melhor indivíduo da população ao invés de selecionar apenas indivíduos aleatórios. Assim, o vetor mutante é gerado adicionando a diferença ponderada entre dois vetores aleatórios ao melhor indivíduo da população. Matematicamente, a geração do vetor mutante  $v_{i,g}$  pode ser expressa como:

$$v_{i,g} = x_{best,g} + F \cdot (x_{r1,g} - x_{r2,g}) \quad (5.16)$$

onde  $F > 0$  é o fator de escala que controla a amplificação das diferenças entre os vetores, e os índices  $r_1$  e  $r_2$  são gerados de maneira aleatória em que  $r_1 \neq r_2 \neq i$ . Ao gerar o vetor mutante  $v_{i,g}$  definido pela Eq. (5.16), os valores são arredondados e ajustados para ficar entre o limite inferior e superior  $[b_{j,L}, b_{j,U}]$ .

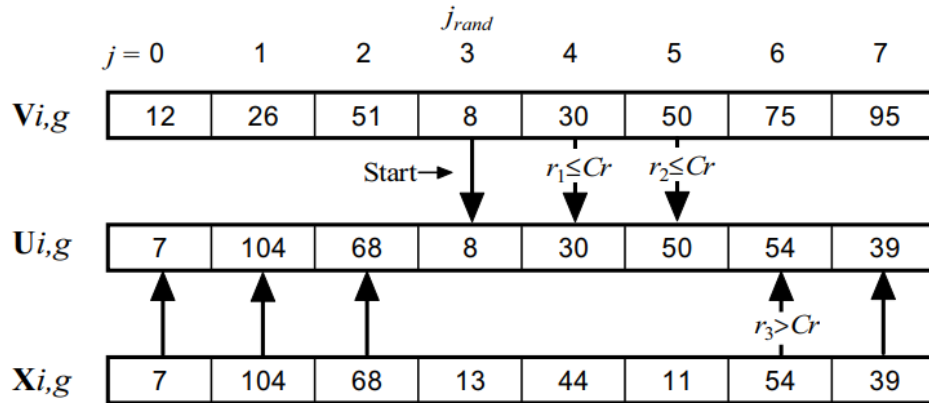
### 5.2.1.2 Cruzamento Exponencial (/exp)

Embora existam diversos métodos de cruzamento, após testes comparativos entre os métodos binomial (/bin) e exponencial (/exp), optou-se pelo segundo, por demonstrar maior eficiência. Para o método exponencial, inicialmente, seleciona-se aleatoriamente um índice de parâmetro, copiando o valor do vetor mutante para o vetor de teste. Isso garante que o vetor de teste seja diferente do vetor no qual será comparado (i.e., o vetor alvo  $x_{i,g}$ ).

Em seguida, para cada parâmetro subsequente, compara-se um número aleatório (uniformemente distribuído no intervalo entre 0 e 1) ao fator de cruzamento  $Cr$ . Enquanto esse número for menor ou igual a  $Cr$ , os valores continuam sendo retirados do vetor mutante. Contudo, na primeira ocasião em que o número aleatório exceder o valor de  $Cr$ , o processo de cópia a partir do vetor mutante é interrompido, e os parâmetros restantes são copiados diretamente do vetor alvo. A Figura 3 ilustra um caso em que o método exponencial produziu dois pontos de cruzamento.



Figura 3 – Cruzamento Exponencial



Fonte: (KENNETH V. PRICE RAINER M. STORN, 2005)

O nome do método exponencial reflete o fato de que o número de parâmetros mutantes herdados é uma variável aleatória distribuída exponencialmente (KENNETH V. PRICE RAINER M. STORN, 2005). O Algoritmo 2 apresenta o pseudo-código do processo de realização da recombinação exponencial.

---

**Algoritmo 2:** Pseudo-código do Cruzamento Exponencial (/exp)

---

**Entrada:**  $x_{i,g}$ : vetor da população (vetor alvo)

**Entrada:**  $v_{i,g}$ : vetor mutante

**Entrada:**  $Cr$ : fator de cruzamento

**Saída:**  $u_{i,g}$ : vetor resultante (teste) do cruzamento

```

1  $u_{i,g} \leftarrow x_{i,g};$ 
2  $j \leftarrow$  número aleatório entre  $[1, |I|];$ 
3  $L \leftarrow 0;$ 
4 repita
5    $u_{j,i} \leftarrow v_{j,i};$            // Filho herda um parâmetro do vetor mutante
6    $j \leftarrow (j + 1) \% |I|;$        // Incrementa j, modulo |I|
7    $L \leftarrow L + 1;$ 
8 até  $L = |I|$  ou  $rand[0, 1) \geq Cr;$ 
9 retorna  $u_{i,g}$ 

```

---

### 5.2.1.3 Seleção

Na fase de seleção, o filho  $u_{i,g}$  compete com o indivíduo alvo  $x_{i,g}$  e o melhor sobrevive passando para próxima geração. É matematicamente expresso como:

$$x_{i,g+1} = \begin{cases} u_{i,g}, & \text{se } f(u_{i,g}) \leq f(x_{i,g}) \\ x_{i,g}, & \text{caso contrário.} \end{cases} \quad (5.17)$$

Na Eq. (5.17)  $f(\cdot) : \mathbb{R}^n \mapsto \mathbb{R}$  é a função objetivo que deve ser minimizada. O DE repete estes processos até que um critério de parada seja satisfeito, retornando o vetor com menor valor de  $f(\cdot)$  ao fim da execução.

## 6 EXPERIMENTOS COMPUTACIONAIS

Este capítulo discute os experimentos computacionais realizados ao longo do trabalho. São apresentados os conjuntos de instâncias utilizadas, o processo de ajuste dos parâmetros do DE e as configurações do ambiente em que foram executados os experimentos.

### 6.1 Conjuntos de Instâncias do Problema

As instâncias de teste propostas e utilizadas na competição ROADEF/EURO Challenge 2020 serão utilizadas para validar o desempenho da estratégia proposta. Essas instâncias representam diferentes cenários e condições operacionais da rede elétrica, permitindo uma avaliação abrangente do algoritmo proposto. Para essa análise, foram selecionados três conjuntos de instâncias, denominados A, B e C, contendo, respectivamente, 15 instâncias cada. O tamanho total desses conjuntos é de 1,3 GB, 9,8 GB e 5,0 GB. Cada instância é armazenada em um arquivo no formato JSON, que, após ser lido e processado, é submetido à etapa de otimização. Informações detalhadas sobre as características de cada conjunto de instâncias estão apresentadas na Tabela 1.

### 6.2 Ajustes de Parâmetros do DE

Como apresentado no capítulo anterior, o DE possui dois parâmetros e que precisam ser ajustados: o fator de mutação ( $F$ ) e o fator de cruzamento ( $Cr$ ). O tamanho da população ( $N_p$ ) foi fixado em 10, uma vez que, ao aumentar o número de indivíduos, observou-se um desempenho inferior do algoritmo. Esse comportamento ocorre porque o DE avalia cada indivíduo da população, e o cálculo da função objetivo  $f(\cdot)$  — que, como discutido anteriormente, valida as restrições do problema e penaliza os indivíduos que as violam — demandava um tempo considerável, comprometendo a eficiência.

Para determinar os valores ideais de  $F$  e  $Cr$  nos experimentos, utilizou-se o *irace*. Desenvolvido em R, o *irace* é um software que implementa métodos de configuração automática de parâmetros. Em especial, ele utiliza procedimentos de corrida iterada, os quais têm demonstrado sucesso na configuração automática de diversos algoritmos.

Dentre esses métodos, destaca-se o *iterated F-race* e suas extensões, que proporcionam melhorias significativas na busca por configurações eficientes (LÓPEZ-IBÁÑEZ et al., 2016).

Portanto, os resultados gerados pelo *irace* para os parâmetros do DE foram:

- $F$  : 0,6235
- $Cr$ : 0,5763

### 6.3 Infraestrutura Computacional e Softwares

Os experimentos foram realizados em uma máquina virtual configurada com 24 *threads*, 96 GB de memória *RAM*, e executando o sistema operacional *Ubuntu 20.04.6 LTS* (64-bit). A máquina física que hospedava a VM estava equipada com dois processadores *Intel Xeon(R) Silver 4116* a 2.10 GHz, operando sob o sistema *Xen Hypervisor*.

A implementação da otimização foi desenvolvida utilizando a linguagem *Python* na versão 3.12.3. Para resolução do modelo matemático, foi utilizado o *Gurobi* versão 12.0.0. Já os ajustes de parâmetros do DE foram realizados com a linguagem *R* na versão 4.4.2, empregando o pacote *irace* na versão 4.1.

Apesar da VM utilizada possuir 24 *threads*, o *Gurobi* e o DE foram executados em uma única *thread* cada.

Conjunto	Instância	Intervenções	Horizonte Tempo	Recursos	Média Cenários	Exclusão	quantil	alpha
A	01	181	90	9	1	81	0,95	0,5
	02	89	90	9	120	32	0,95	0,5
	03	91	90	10	1	12	0,95	0,5
	04	706	365	9	1	1377	0,95	0,5
	05	180	182	9	120	87	0,95	0,5
	06	180	182	10	1	87	0,95	0,5
	07	36	17	9	6	3	0,5	0,5
	08	18	17	9	646	4	0,95	0,5
	09	18	17	9	6	0	0,5	0,5
	10	108	53	10	6	40	0,5	0,5
	11	54	53	9	640	4	0,95	0,5
	12	54	53	10	6	0	0,5	0,5
	13	179	90	9	12	136	0,5	0,5
	14	108	90	10	160	22	0,95	0,5
	15	108	53	10	320	22	0,95	0,5
B	01	100	53	9	191	26	0,9	0,5
	02	100	53	9	191	19	0,9	0,5
	03	706	53	9	63	1192	0,9	0,5
	04	706	53	9	63	1192	0,9	0,5
	05	706	53	9	63	1337	0,9	0,5
	06	100	53	9	255	19	0,9	0,5
	07	250	53	9	191	186	0,8	0,5
	08	119	42	9	254	37	0,95	0,5
	09	120	42	9	127	44	0,95	0,5
	10	398	25	9	192	344	0,8	0,5
	11	100	53	9	191	34	0,9	0,5
	12	495	102	9	63	570	0,95	0,5
	13	99	102	9	159	4	0,9	0,5
	14	297	191	9	95	207	0,8	0,5
	15	495	250	9	63	665	0,8	0,5
C	01	120	53	9	191	54	0,95	0,5
	02	120	53	9	191	43	0,8	0,5
	03	706	53	9	63	1223	0,85	0,5
	04	706	53	9	63	1194	0,9	0,5
	05	706	53	9	63	1377	0,95	0,5
	06	280	53	9	191	183	0,8	0,5
	07	120	42	9	126	38	0,95	0,5
	08	426	25	9	192	340	0,8	0,5
	09	110	53	9	191	38	0,9	0,5
	10	522	102	9	63	705	0,95	0,5
	11	89	102	9	191	35	0,9	0,5
	12	298	191	9	95	195	0,8	0,5
	13	505	230	9	63	53	0,95	0,5
	14	465	220	9	95	620	0,85	0,5
	15	528	300	9	51	624	0,95	0,5

Tabela 1 – Características das instâncias propostas para competição ROADEF/EURO Challenge 2020 e utilizadas nos experimentos computacionais

## 7 RESULTADOS

Neste capítulo é apresentado os resultados obtidos pela implementação da estratégia híbrida Gurobi/DE para execução em 15 minutos, incluindo o tempo de leitura da instância e criação do modelo.

Ao analisar os resultados individuais de cada conjunto de instâncias, pode-se perceber que a dificuldade de chegar no valor ótimo aumenta consideravelmente a medida que o tamanho da entrada aumenta. O Gurobi/DE conseguiu encontrar o valor ótimo em 5 das 15 instâncias do conjunto A, chegando bem próximo das demais como ilustrado na Figura 4.

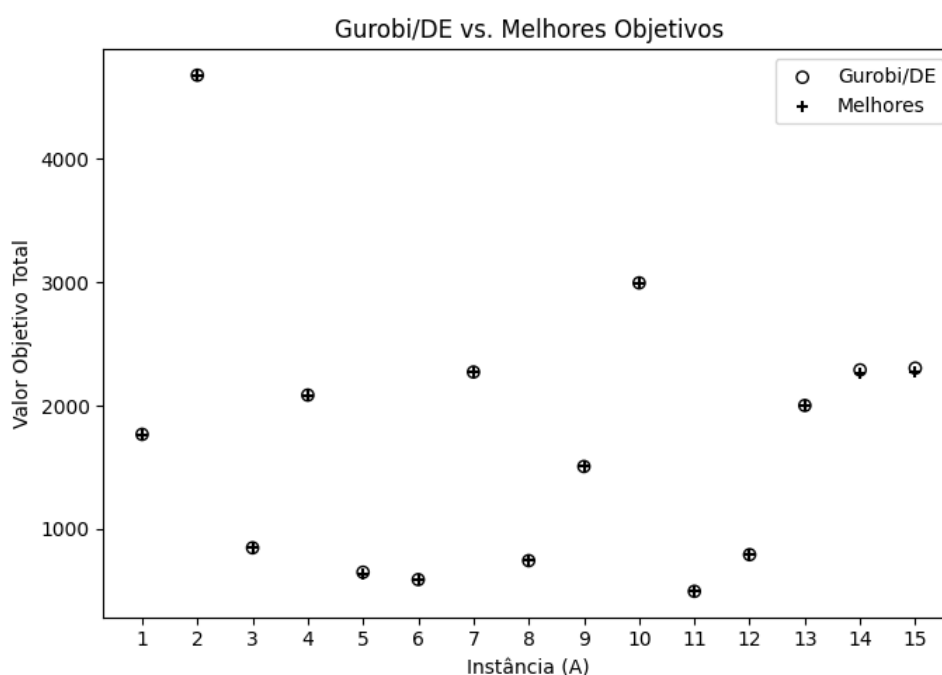


Figura 4 – Resultados do Gurobi/DE para instância A em 15 minutos

Nos conjuntos de instâncias B e C, observa-se que o aumento no número de intervenções, cenários, e planejamentos muito restritivos, torna o problema ainda mais complexo, dificultando a convergência para o valor ótimo em apenas 15 minutos. Apesar disso, o Gurobi/DE conseguiu obter resultados próximos ao ótimo em várias instâncias. As Figuras Figura 5 e Figura 6 apresentam os resultados para os conjuntos B e C, respectivamente.




Figura 5 – Resultados do Gurobi/DE para instância B em 15 minutos




Figura 6 – Resultados do Gurobi/DE para instância C em 15 minutos

A Tabela 2 apresenta uma visão consolidada dos resultados obtidos, destacando o valor do risco médio, excesso esperado e a diferença relativa percentual em relação ao ótimo global. Esses dados possibilitam a análise do desempenho do Gurobi/DE em

diferentes cenários e tamanhos de instâncias.

Conjunto	Instância	Risco Médio	Excesso Esperado	Melhor	Gurobi/DE	%Dif
A	01	3535,631222	0	1767,815611	<b>1767,815611</b>	0,0000
	02	4241,336325	5115,412564	4671,376611	4678,374444	0,1498
	03	1696,357222	0	848,178611	<b>848,178611</b>	0,0000
	04	4171,950986	0	2085,876054	2085,975493	0,0048
	05	1182,542018	118,314026	635,221786	650,428022	2,3938
	06	1181,280990	0	590,623599	590,640495	0,0029
	07	4545,564549	0	2272,782274	<b>2272,782274</b>	0,0000
	08	1333,708024	154,878447	744,293235	<b>744,293235</b>	0,0000
	09	3012,724863	1,844706	1507,284784	<b>1507,284784</b>	0,0000
	10	5975,586868	15,107226	2994,848735	2995,347047	0,0166
	11	919,163756	72,298916	495,255770	495,731336	0,0960
	12	1552,594704	32452736	789,634928	792,52372	0,3658
	13	3998,500685	5,129213	1998,662162	2001,814949	0,1577
	14	4114,331946	465,219374	2264,124321	2289,77566	1,1329
	15	4131,044048	477,892745	2268,569150	2304,468396	1,5825
B	01	3601,706990	6268,728859	3986,202830	4935,217925	23,8075
	02	4179,391361	5489,497318	4302,774528	4834,44434	12,3564
	03	23734,481819	61767,30875	35279,530189	42750,89528	21,1776
	04	27627,918278	46133,07229	34827,869811	36880,49528	5,8936
	05	2781,787073	3447,029908	2397,099057	3114,408491	29,9241
	06	4311,891097	5024,665507	4287,894340	4668,278302	8,8711
	07	9737,243507	6040,45838	7564,034906	7888,850943	4,2942
	08	5134,904748	9926,350014	7435,719048	7530,627381	1,2764
	09	3617,860235	18171,23262	7491,753571	10894,54644	45,4205
	10	11650,622222	10257,48978	10637,620000	10954,056	2,9747
	11	3645,395214	4330,461389	3626,271698	3987,928302	9,9732
	12	21874,409423	60859,96019	37602,966667	41385,1848	10,0583
	13	4888,876416	5636,976525	5024,492647	5262,926471	4,7454
	14	14812,173946	9612,840714	11905,109948	12212,50733	2,5821
	15	19701,762196	27922,1394	22566,003400	23811,9508	5,5213
C	01	4803,720272	13611,27029	8515,903773	9207,495283	8,1212
	02	4438,078198	2852,989727	3541,653773	3645,533962	2,9331
	03	23282,019443	54478,83905	33511,700000	38880,42925	16,0205
	04	26095,208740	53305,69126	37585,731132	39700,45	5,6264
	05	2540,515185	5871,713117	3166,889622	4206,114151	32,8153
	06	9382,644700	7992,126998	8396,000943	8687,385849	3,4705
	07	3797,702435	11483,79518	6083,270238	7618,2488	25,2328
	08	13011,670118	10134,56188	11162,836000	11573,116	3,6754
	09	4173,610492	8803,821583	5586,979245	6488,716038	16,1400
	10	26603,591672	74615,22205	43342,488725	50609,40686	16,7663
	11	4918,126650	7195,403742	5749,957352	6056,765196	5,3358
	12	13832,754366	12527,03726	12721,133246	13179,89581	3,6063
	13	25460,910463	67653,94649	42487,992826	46557,42848	9,5778
	14	21393,880599	35278,36031	26467,221136	28336,12045	7,0612
	15	27829,167623	59244,55071	39758,027500	43536,85917	9,5046

Tabela 2 – Resultados obtidos pelo Gurobi/DE com tempo de execução de 15 minutos

Ao avaliar os resultados apresentados na Tabela Tabela 2, observa-se que, na maioria das instâncias, houve valor de excesso. Nesse sentido, o DE conseguiu refinar a



solução gerada pelo Gurobi e aproximar-se do resultado da competição para a instância A. No entanto, para as demais instâncias, que possuem porte de médio a grande, o aumento na quantidade de intervenções, cenários e exclusões dificultou o refinamento das soluções geradas pelo Gurobi. Acredita-se que essa dificuldade esteja associada ao tempo limitado e à complexidade computacional, já que o DE era executado apenas com o tempo restante após a execução do Gurobi. Além disso, para instâncias de maior dimensão, o *Python* demandava um tempo significativo para a avaliação da função objetivo.

Embora a estratégia de recriação da população mantendo o melhor indivíduo tenha sido empregada, o DE frequentemente ficava preso em mínimos locais. Devido à limitação de tempo, o algoritmo não conseguia escapar desses mínimos, comprometendo a qualidade final das soluções.

## 8 CONSIDERAÇÕES FINAIS

### 8.1 Conclusões

Este trabalho abordou o problema de planejamento de manutenções preventivas em redes de transmissão de energia elétrica, utilizando como referência o desafio proposto pelo ROADEF/EURO Challenge 2020, promovido pela Réseau de Transport d'Électricité (RTE).

Foi desenvolvido um modelo de Programação Linear Inteira Mista com o objetivo de minimizar os riscos associados às manutenções, respeitando as restrições operacionais e de recursos. A partir da modelagem proposta, implementou-se uma abordagem híbrida que combina o *solver* Gurobi com uma heurística baseada no algoritmo de Evolução Diferencial (DE).

A abordagem híbrida mostrou-se promissora para resolver o problema de otimização combinatória. Enquanto o DE demonstrou ser capaz, com uma população menor, de explorar o espaço de busca de maneira eficiente e convergir para regiões próximas do ótimo global, o uso do Gurobi foi importante para obter soluções factíveis. Como o modelo do Gurobi desconsidera excessos de risco, o DE complementou a abordagem ao refinar a busca em instâncias onde esses excessos estavam presentes.

Entretanto, a implementação em *Python* revelou-se um gargalo em termos de desempenho. Desde a leitura e interpretação (*parsing*) dos arquivos de entrada até o cálculo da função objetivo e das penalidades das restrições, o custo computacional foi elevado. Além disso, a incapacidade de executar o DE de forma paralela (*CPU-bound*) limitou uma das principais vantagens do método, que é a avaliação simultânea dos indivíduos da população.

Apesar dessas limitações, o uso do *Python* facilitou o desenvolvimento da abordagem híbrida e a integração com o Gurobi. Este trabalho validou a viabilidade da ideia e demonstrou o potencial do DE em combinação com métodos que exploram grandes espaços de busca, refinando a busca para a obtenção de soluções de qualidade.

## 8.2 Trabalhos Futuros

Como possibilidade de trabalhos futuros, pode-se implementar o DE em uma linguagem de programação que suporte paralelização de maneira eficiente, como *C++* ou *Julia*, a fim de melhorar o desempenho do algoritmo.

Além disso, explorar novas abordagens de hibridização com outras meta-heurísticas pode ser uma estratégia promissora para aumentar a eficiência do processo de refinamento a segunda etapa da estratégia proposta.

## REFERÊNCIAS

BELDICEANU, Nicolas. Pruning for the Minimum Constraint Family and for the Number of Distinct Values Constraint Family. In: WALSH, Toby (Ed.). **Principles and Practice of Constraint Programming — CP 2001**. Berlin, Heidelberg: Springer Berlin Heidelberg, 2001. P. 211–224. ISBN 978-3-540-45578-3.

BERTSIMAS, Dimitris; TSITSIKLIS, John. **Introduction to Linear Optimization**. 1st. [S.l.]: Athena Scientific, 1997. ISBN 1886529191.

CATTARUZZA, Diego et al. Exact and Heuristic Solution Techniques for Mixed-Integer Quantile Minimization Problems. **INFORMS Journal on Computing**, v. 36, n. 4, p. 1084–1107, 2024. DOI: 10.1287/ijoc.2022.0105. Disponível em: <<https://doi.org/10.1287/ijoc.2022.0105>>.

CODATO, Gianni; FISCHETTI, Matteo. Combinatorial Benders' Cuts for Mixed-Integer Linear Programming. **Operations Research**, v. 54, n. 4, p. 756–766, 2006. Disponível em: <<https://doi.org/10.1287/opre.1060.0286>>.

CROGNIER, Guillaume et al. Grid operation-based outage maintenance planning. **Electric Power Systems Research**, Elsevier Ltd, v. 190, jan. 2021. ISSN 03787796. DOI: 10.1016/j.epsr.2020.106682.

EHRGOTT, Matthias; GANDIBLEUX, Xavier. A survey and annotated bibliography of multiobjective combinatorial optimization. **OR-Spektrum**, v. 22, n. 4, p. 425–460, nov. 2000. ISSN 1436-6304. DOI: 10.1007/s002910000046. Disponível em: <<https://doi.org/10.1007/s002910000046>>.

GENDREAU, Michel; POTVIN, Jean-Yves (Ed.). **Handbook of Metaheuristics**. 3. ed. Cham: Springer International Publishing, 2019. P. xx, 604. (International Series in Operations Research Management Science). Springer International Publishing AG, part of Springer Nature 2019. ISBN 978-3-319-91086-4. DOI: <https://doi.org/10.1007/978-3-319-91086-4>. Disponível em: <<https://doi.org/10.1007/978-3-319-91086-4>>.

GLOVER, Fred. Optimization by ghost image processes in neural networks. **Computers Operations Research**, v. 21, n. 8, p. 801–822, 1994. Heuristic, Genetic and Tabu Search.

ISSN 0305-0548. DOI: [https://doi.org/10.1016/0305-0548\(94\)90012-4](https://doi.org/10.1016/0305-0548(94)90012-4). Disponível em: <<https://www.sciencedirect.com/science/article/pii/0305054894900124>>.

GOUVINE, Gabriel. Mixed-Integer Programming for the ROADEF/EURO 2020 challenge, nov. 2021. Disponível em: <<http://arxiv.org/abs/2111.01047>>.

GU, Hanyu et al. Heuristics and meta-heuristic to solve the ROADEF/EURO challenge 2020 maintenance planning problem. **Journal of Heuristics**, Springer, v. 29, p. 139–175, 1 fev. 2023. ISSN 15729397. DOI: 10.1007/s10732-022-09508-1.

INTERNATIONAL ENERGY AGENCY. **Electricity 2024 - Analysis and forecast to 2026**. [S.l.], 2024. Available in PDF. Disponível em: <<https://www.iea.org/>>.

KENNETH V. PRICE RAINER M. STORN, Jouni A. Lampinen. The Differential Evolution Algorithm. In: DIFFERENTIAL Evolution: A Practical Approach to Global Optimization. Berlin, Heidelberg: Springer Berlin Heidelberg, 2005. P. 37–134. ISBN 978-3-540-31306-9. DOI: 10.1007/3-540-31306-0\_2. Disponível em: <[https://doi.org/10.1007/3-540-31306-0\\_2](https://doi.org/10.1007/3-540-31306-0_2)>.

KORTE, Bernhard; VYGEN, Jens. NP-Completeness. In: COMBINATORIAL Optimization: Theory and Algorithms. Berlin, Heidelberg: Springer Berlin Heidelberg, 2018. P. 385–421. ISBN 978-3-662-56039-6. DOI: 10.1007/978-3-662-56039-6\_15. Disponível em: <[https://doi.org/10.1007/978-3-662-56039-6\\_15](https://doi.org/10.1007/978-3-662-56039-6_15)>.

LAM, Hue Chi (Trudy). **Scheduling with Two Types of Penalties Under Uncertainty and Its Application to Maintenance Planning**. 2022. Tese (Doutorado) – Faculty of Science, University of Technology Sydney, Sydney.

LIMA MARTINS, Simone de; ROSSETI, Isabel; PLASTINO, Alexandre. Data Mining in Stochastic Local Search. In: **Handbook of Heuristics**. Edição: Rafael Martí, Panos M. Pardalos e Mauricio G. C. Resende. Cham: Springer International Publishing, 2018. P. 39–87. ISBN 978-3-319-07124-4. DOI: 10.1007/978-3-319-07124-4\_11. Disponível em: <[https://doi.org/10.1007/978-3-319-07124-4\\_11](https://doi.org/10.1007/978-3-319-07124-4_11)>.

LÓPEZ-IBÁÑEZ, Manuel et al. The irace package: Iterated racing for automatic algorithm configuration. **Operations Research Perspectives**, v. 3, p. 43–58, 2016. ISSN 2214-7160. DOI: <https://doi.org/10.1016/j.orp.2016.09.002>. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S2214716015300270>>.

MARKOWITZ, Harry. Portfolio Selection. **The Journal of Finance**, v. 7, n. 1, p. 77–91, 1952.

MARTÍ, Rafael; PARDALOS, Panos M.; RESENDE, Mauricio G. C. (Ed.). **Handbook of Heuristics**. 1. ed. Cham: Springer International Publishing, 2018. P. xxi, 1385. (Mathematics and Statistics, Reference Module Computer Science and Engineering). Springer International Publishing AG, part of Springer Nature 2018. ISBN 978-3-319-07123-7. DOI: 10.1007/978-3-319-07124-4. Disponível em: <<https://doi.org/10.1007/978-3-319-07124-4>>.

MITCHELL, John E. Integer programming: cutting plane algorithms Integer Programming: Cutting Plane Algorithms. In: **Encyclopedia of Optimization**. Edição: Christodoulos A. Floudas e Panos M. Pardalos. Boston, MA: Springer US, 2009. P. 1650–1657. ISBN 978-0-387-74759-0. DOI: 10.1007/978-0-387-74759-0\_288. Disponível em: <[https://doi.org/10.1007/978-0-387-74759-0\\_288](https://doi.org/10.1007/978-0-387-74759-0_288)>.

OGRYCZAK, Włodzimierz; RUSZCZYNSKI, Andrzej. Dual Stochastic Dominance and Related Mean-Risk Models. **SIAM Journal on Optimization**, v. 13, n. 1, p. 60–78, 2002. DOI: 10.1137/S1052623400375075. eprint: <https://doi.org/10.1137/S1052623400375075>. Disponível em: <<https://doi.org/10.1137/S1052623400375075>>.

PARREÑO, Francisco; PARREÑO-TORRES, Consuelo; ALVAREZ-VALDES, Ramon. A matheuristic algorithm for the maintenance planning problem at an electricity transmission system operator. **Expert Systems with Applications**, Elsevier Ltd, v. 230, nov. 2023. ISSN 09574174. DOI: 10.1016/j.eswa.2023.120583.

RUIZ, Manuel; TOURNEBISE, Pascal; RTE, Patrick Panciatici. **ROADEF Challenge RTE: Grid operation-based outage maintenance planning**. [S.l.: s.n.], 2020.

SCHRIJVER, Alexander; COOK, William. In: COMBINATORIAL Optimization. [S.l.]: John Wiley Sons, Ltd, 1997. P. i–x. ISBN 9781118033142. DOI: <https://doi.org/10.1002/9781118033142.fmatter>.

SILVA, André Luiz Maravilha. **Algoritmo baseado em evolução diferencial para solução de problemas de otimização combinatória**. 2014. F. 86. Dissertação de Mestrado – Universidade Federal de Minas Gerais, Escola de Engenharia, Belo Horizonte, Brasil. Orientador: Felipe Campelo França Pinto; Coorientador: Jaime Arturo Ramírez.

STORN, Rainer; PRICE, Kenneth. Differential Evolution – A Simple and Efficient Heuristic for global Optimization over Continuous Spaces. **Journal of Global Optimization**, v. 11, n. 4, p. 341–359, dez. 1997. ISSN 1573-2916. DOI: 10.1023/A:1008202821328. Disponível em: <<https://doi.org/10.1023/A:1008202821328>>.

VASQUEZ, Michel; BULJUBASIC, Mirsad; HANAFI, Saïd. An efficient scenario penalization matheuristic for a stochastic scheduling problem. **Journal of Heuristics**, Springer, v. 29, p. 383–408, 2-3 jun. 2023. ISSN 15729397. DOI: 10.1007/s10732-023-09513-y.

WOLLER, David; RADA, Jakub; KULICH, Miroslav. The ALNS metaheuristic for the transmission maintenance scheduling. **Journal of Heuristics**, Springer, v. 29, p. 349–382, 2-3 jun. 2023. ISSN 15729397. DOI: 10.1007/s10732-023-09514-x.

WOLSEY, Laurence. Formulations. In: **INTEGER Programming**. [S.l.]: John Wiley Sons, Ltd, 2020. cap. 1, p. 1–23. ISBN 9781119606475. DOI: <https://doi.org/10.1002/9781119606475.ch1>. Disponível em: <<https://onlinelibrary.wiley.com/doi/abs/10.1002/9781119606475.ch1>>.